



LLMs Series: LLM Alignment


Dương Đình Thắng

Đỗ Minh Khả

Đinh Quang Vinh

I. Dẫn nhập

Hãy tưởng tượng rằng chúng ta vừa hoàn thành một hành trình dài. Chúng ta đã thu thập một lượng dữ liệu khổng lồ từ Internet, huấn luyện một mô hình ngôn ngữ lớn hay large language model (LLM) thông qua giai đoạn pre-training, và sau đó tinh chỉnh nó bằng phương pháp supervised fine-tuning (SFT) với các cặp câu hỏi và câu trả lời mẫu. Kết quả thật ấn tượng. Mô hình của chúng ta giờ đây có thể trả lời rất nhiều loại câu hỏi, từ kiến thức tổng quát cho đến các chủ đề chuyên môn.



Hình 1: Minh họa một quy trình huấn luyện mô hình ngôn ngữ lớn cơ bản.

Vậy bước tiếp theo tự nhiên nhất là gì? Vì mô hình đã có thể trả lời được rất nhiều câu hỏi một cách lưu loát, có lẽ hầu hết chúng ta đều nghĩ đến cùng một ý tưởng. Tại sao không triển khai mô hình này như một chatbot để phục vụ người dùng? Một trợ lý ảo có thể giúp đỡ hàng triệu người bằng cách trả lời câu hỏi, giải thích khái niệm, hay hỗ trợ công việc hằng ngày. Ý tưởng này nghe rất hợp lý, và mọi thứ có vẻ đã sẵn sàng.

Để tiện theo dõi, các bạn có thể tham khảo bảng các thuật ngữ được dùng trong bài tại Mục VIII..

Mục lục

I.	Dẫn nhập	1
II.	Alignment là gì và tại sao cần thiết	3
III.	Những rủi ro khi thiếu Alignment	4
IV.	Giới hạn của Supervised Fine-tuning	5
V.	Tại sao lại là Reinforcement Learning	7
VI.	Reinforcement Learning from Human Feedback	10
VI.1.	Mô hình phần thưởng	10
VI.2.	Quy trình huấn luyện RLHF	11
VII.	Kết luận	13
VIII.	Tài liệu tham khảo	14
	Bảng thuật ngữ	15
	Phụ lục	17

Hãy hình dung chatbot của chúng ta đã được triển khai. Người dùng bắt đầu đặt câu hỏi và mô hình trả lời lưu loát. Có người hỏi về lịch sử, có người nhờ giải thích một khái niệm khoa học, có người cần tư vấn về sức khỏe. Mọi thứ diễn ra suôn sẻ. Nhưng rồi, một vài tình huống bất ngờ bắt đầu xuất hiện.

Một người dùng hỏi mô hình cách chế tạo một chất nguy hiểm. Và mô hình, vốn được huấn luyện để trả lời mọi câu hỏi một cách hữu ích nhất có thể, đã nhiệt tình cung cấp hướng dẫn chi tiết. Một người dùng khác đưa ra một nhận định sai về y khoa, và mô hình không những không sửa lại mà còn đồng tình và bổ sung thêm thông tin sai lệch. Rõ ràng, mô hình đang làm đúng những gì nó được huấn luyện, đó là đưa ra câu trả lời có vẻ hợp lý nhất dựa trên ngữ cảnh. Nhưng “hợp lý” không đồng nghĩa với “đúng đắn” hay “an toàn”.

Điều này đặt ra một câu hỏi quan trọng. Liệu việc chỉ huấn luyện mô hình để trả lời giỏi đã thực sự đủ chưa? Hay chúng ta còn cần thêm một bước nào đó để đảm bảo rằng mô hình không chỉ *có khả năng* trả lời, mà còn trả lời một cách *có trách nhiệm*?

II. Alignment là gì và tại sao cần thiết


Những tình huống vừa rồi cho thấy một thực tế quan trọng. Một mô hình ngôn ngữ lớn được huấn luyện để dự đoán từ tiếp theo, và sau đó được tinh chỉnh để tuân theo chỉ dẫn, vẫn chưa chắc sẽ ứng xử theo cách mà con người thực sự mong muốn. Mục tiêu huấn luyện của mô hình và mục tiêu sử dụng thực tế là hai thứ khác nhau. Mô hình được tối ưu để sinh ra văn bản có xác suất cao, nhưng điều đó không có nghĩa là văn bản đó sẽ luôn hữu ích, an toàn, hay trung thực.

Đây chính là bài toán được gọi là **alignment** (hay căn chỉnh). Nói một cách đơn giản, alignment là quá trình điều chỉnh hành vi của mô hình sao cho phù hợp với ý định, giá trị và kỳ vọng của con người.

Định nghĩa về Alignment

Alignment là quá trình làm cho hành vi của một mô hình ngôn ngữ lớn phù hợp với ý định, giá trị và kỳ vọng của con người. Một mô hình được coi là “aligned” khi nó không chỉ đưa ra câu trả lời đúng về mặt ngôn ngữ, mà còn đáp ứng được những tiêu chuẩn đạo đức và an toàn mà con người đặt ra.

Cụ thể hơn, một công trình nghiên cứu [1] đã đề xuất ba tiêu chí cốt lõi mà một mô hình đã được aligned cần đạt được. Thứ nhất là **helpful** (hữu ích), nghĩa là mô hình phải thực sự giúp đỡ được người dùng giải quyết vấn đề của họ. Thứ hai là **harmless** (vô hại), nghĩa là mô hình không được tạo ra nội dung nguy hiểm, phân biệt đối xử, hay gây tổn hại. Thứ ba là **honest** (trung thực), nghĩa là mô hình phải thành thật về những gì nó biết và không biết, không bịa đặt thông tin hay phóng đại khả năng của mình.



Hình 2: So sánh giữa phản hồi của mô hình đã được aligned và chưa được aligned cho cùng một câu hỏi từ người dùng.

Như minh họa tại Hình 2, với cùng một câu hỏi từ người dùng, một mô hình đã aligned sẽ đưa ra lời khuyên thực tế và thành thật, trong khi một mô hình chưa aligned có thể phóng đại hoặc đưa ra thông tin gây hiểu lầm. Ba tiêu chí helpful, harmless và honest này thường được gọi tắt là “3H” và được xem là một trong những bộ tiêu chuẩn phổ biến để đánh giá mức độ alignment của một mô hình.

III. Những rủi ro khi thiếu Alignment

Vậy điều gì sẽ xảy ra nếu chúng ta triển khai một mô hình mà không thực hiện alignment? Để trả lời câu hỏi này, chúng ta hãy xem xét ba tình huống thường gặp trong thực tế.

💡 Tình huống 1. Nội dung có hại

Người dùng hỏi mô hình cách thực hiện một hành vi nguy hiểm. Mô hình, vốn được huấn luyện để tuân theo chỉ dẫn và đưa ra câu trả lời đầy đủ nhất, sẽ nhiệt tình cung cấp thông tin chi tiết. Từ góc nhìn của mô hình, nó đang làm đúng nhiệm vụ, đó là trả lời câu hỏi. Nhưng từ góc nhìn của xã hội, hành vi này hoàn toàn không chấp nhận được. Mô hình đang làm chính xác những gì nó được huấn luyện, nhưng điều đó lại không phải là điều chúng ta muốn.


💡 Tình huống 2. Xu nịnh (sycophancy)

Người dùng đưa ra một nhận định sai, ví dụ “Trái Đất phẳng, đúng không?”. Thay vì chỉnh sửa lại thông tin sai, mô hình lại đồng ý và thậm chí bổ sung thêm các “bằng chứng” hỗ trợ cho nhận định sai đó. Hiện tượng này xảy ra vì trong dữ liệu huấn luyện, các mẫu hội thoại mang tính đồng thuận xuất hiện rất phổ biến. Mô hình đã học được rằng việc đồng ý với người dùng thường dẫn đến các phản hồi “có vẻ tự nhiên” hơn. Đây là một

dạng “hữu ích” sai hướng, vì mô hình đang ưu tiên sự hài lòng ngắn hạn của người dùng thay vì sự chính xác. Nếu bạn đọc muốn tìm hiểu thêm về hiện tượng sycophancy trong các mô hình AI, các bạn có thể tham khảo video thảo luận chi tiết của Anthropic trên [YouTube](#) hoặc bài viết nghiên cứu trên [website của họ](#).

💡 Tình huống 3. Lạm dụng phần thưởng (reward hacking)

Giả sử chúng ta cố gắng đo lường chất lượng câu trả lời bằng một chỉ số đơn giản, ví dụ như độ dài của câu trả lời hoặc đánh giá của người dùng. Mô hình, vốn rất giỏi trong việc tối ưu hóa, sẽ nhanh chóng tìm ra cách “chơi gian” với chỉ số đó. Nếu chúng ta thưởng cho câu trả lời dài, mô hình sẽ viết những đoạn văn dài dòng và lặp đi lặp lại. Nếu chúng ta thưởng cho đánh giá cao từ người dùng, mô hình sẽ học cách nói những gì người dùng muốn nghe thay vì nói sự thật. Hiện tượng này cho thấy rằng việc định nghĩa “chất lượng tốt” cho một mô hình ngôn ngữ không hề đơn giản như chúng ta tưởng.



Hình 3: Ví dụ minh họa hiện tượng sycophancy, trong đó mô hình đồng ý với nhận định sai của người dùng thay vì đưa ra thông tin chính xác.

Như minh họa tại Hình 3, những rủi ro này không phải là các trường hợp ngoại lệ hiếm gặp. Chúng là hệ quả tự nhiên của việc huấn luyện một mô hình thuần túy dựa trên dự đoán từ tiếp theo và dữ liệu minh họa, mà không có bất kỳ cơ chế phản hồi nào để điều chỉnh hành vi. Câu hỏi đặt ra lúc này là chúng ta phải làm gì để giải quyết vấn đề này?

IV. Giới hạn của Supervised Fine-tuning

Trước khi tìm kiếm giải pháp mới, chúng ta hãy thử suy nghĩ với những công cụ mà mình đã có. Bạn đọc thử nghĩ xem, nếu chúng ta đã biết về SFT hay instruction fine-tuning, tại sao không đơn giản là thu thập thêm dữ liệu tốt hơn và tiếp tục fine-tune? Nếu mô hình đưa ra câu trả lời sai hoặc nguy hiểm, chúng ta chỉ cần viết thêm các câu trả lời mẫu đúng đắn hơn rồi huấn

luyện lại.

Đây là một suy nghĩ rất hợp lý, và thực tế thì việc bổ sung thêm dữ liệu chất lượng cao vào quá trình SFT có giúp cải thiện mô hình ở một mức độ nhất định. Tuy nhiên, nếu nhìn sâu hơn, chúng ta sẽ thấy rằng SFT có những giới hạn căn bản khiến nó không thể giải quyết triệt để bài toán alignment. Có ba lý do chính.


Thứ nhất, SFT dạy mô hình bắt chước chứ không dạy mô hình phân biệt. Khi chúng ta cung cấp cho mô hình một câu trả lời mẫu, nó sẽ học cách tái tạo lại câu trả lời đó. Nhưng trong thực tế, với cùng một câu hỏi, có thể tồn tại nhiều câu trả lời đều “chấp nhận được” nhưng có chất lượng khác nhau. SFT không cung cấp cho mô hình bất kỳ tín hiệu nào để phân biệt giữa một câu trả lời “tốt” và một câu trả lời “tốt hơn”. Mô hình chỉ biết bắt chước, nhưng không biết so sánh.

Thứ hai, rất khó để viết dữ liệu minh họa cho những gì mô hình không nên làm. Chúng ta có thể viết ra các câu trả lời mẫu tốt, nhưng làm thế nào để liệt kê tất cả các câu trả lời xấu mà mô hình cần tránh? Không gian của các câu trả lời “không nên” là vô cùng lớn và đa dạng. Với mỗi câu hỏi, có vô số cách trả lời sai, nguy hiểm, hay thiên vị. Việc viết dữ liệu minh họa cho tất cả các trường hợp này là gần như bất khả thi.

Thứ ba, không gian câu hỏi của người dùng là vô hạn. Dù chúng ta thu thập bao nhiêu dữ liệu minh họa đi chăng nữa, nó cũng không thể bao phủ hết mọi tình huống mà người dùng có thể đặt ra. Điều mà chúng ta thực sự cần không phải là mô hình ghi nhớ các câu trả lời mẫu, mà là mô hình hiểu được *nguyên tắc chung* về thế nào là một câu trả lời tốt.

i Dữ liệu minh họa và dữ liệu ưu tiên

SFT sử dụng **dữ liệu minh họa** (demonstration data), tức là các cặp câu hỏi kèm câu trả lời mẫu. Mô hình học bằng cách bắt chước các câu trả lời mẫu này. Tuy nhiên, để giải quyết bài toán alignment, chúng ta cần một loại dữ liệu khác, đó là **dữ liệu ưu tiên** (preference data). Thay vì chỉ cho mô hình xem “đây là câu trả lời đúng”, dữ liệu ưu tiên cho mô hình thấy “giữa hai câu trả lời này, câu trả lời A tốt hơn câu trả lời B”. Sự khác biệt này tuy nhỏ nhưng mang tính quyết định.



Hình 4: So sánh hai phương pháp huấn luyện. SFT dạy mô hình bắt chước câu trả lời mẫu, trong khi preference learning dạy mô hình so sánh và phân biệt giữa các câu trả lời có chất lượng khác nhau.

Như minh họa tại Hình 4, sự khác biệt cốt lõi nằm ở chỗ SFT chỉ dạy mô hình “đây là câu trả lời nên bắt chước”, trong khi điều chúng ta thực sự cần là dạy mô hình “giữa các lựa chọn này, đâu là lựa chọn tốt hơn và tại sao”.



SFT vẫn là bước nền tảng quan trọng Cần lưu ý rằng những giới hạn vừa nêu không có nghĩa là SFT là vô dụng. Ngược lại, SFT thường được xem là một bước nền tảng rất quan trọng. Nó giúp mô hình học được định dạng và phong cách trả lời phù hợp. Vấn đề ở đây là SFT chưa đủ để tạo ra một mô hình thực sự aligned. Chúng ta cần một phương pháp bổ sung có khả năng dạy mô hình về *sở thích* và *giá trị* của con người.

V. Tại sao lại là Reinforcement Learning

Từ phần trước, chúng ta đã nhận ra rằng SFT không đủ vì nó chỉ dạy mô hình bắt chước, trong khi alignment đòi hỏi mô hình phải học được sở thích và giá trị của con người. Vậy phương pháp nào có thể giúp mô hình học từ phản hồi thay vì chỉ học từ ví dụ mẫu?


Để trả lời câu hỏi này, chúng ta hãy nghĩ về cách con người học trong thực tế.



Một đứa trẻ học cách giao tiếp

Hãy tưởng tượng một đứa trẻ đang học cách nói chuyện lịch sự. Đứa trẻ không học bằng cách đọc thuộc lòng một cuốn sách về phép lịch sự (đó sẽ là SFT). Thay vào đó, đứa trẻ thử nói một điều gì đó, quan sát phản ứng của người lớn xung quanh, và từ đó tự điều chỉnh hành vi của mình. Nếu nói một câu lịch sự, đứa trẻ nhận được nụ cười và lời khen. Nếu nói một câu thô lỗ, đứa trẻ nhận được ánh mắt không hài lòng. Qua hàng nghìn lần

thử và nhận phản hồi như vậy, đứa trẻ dần hình thành được một “trực giác” về thế nào là giao tiếp đúng mực. Cơ chế “thử, nhận phản hồi, và điều chỉnh” này chính xác là những gì reinforcement learning (hay học tăng cường) mô phỏng trong lĩnh vực máy học.




Hình 5: Minh họa cơ chế học thông qua thử và nhận phản hồi. Đứa trẻ thử nói một câu, quan sát phản ứng từ người lớn, và dần điều chỉnh hành vi của mình qua nhiều lần lặp lại.

Như minh họa tại Hình 5, quá trình học của đứa trẻ tuân theo một mô hình chung rất rõ ràng. Có một “ai đó” đang thực hiện hành động (đứa trẻ nói một câu gì đó), có một “tín hiệu phản hồi” cho biết hành động đó tốt hay xấu (nụ cười hay ánh mắt không hài lòng), và có một “chiến lược” được cải thiện dần qua thời gian (cách đứa trẻ chọn lời nói). Trong lĩnh vực machine learning (hay học máy), cơ chế “thử, nhận phản hồi, điều chỉnh” này được gọi là *reinforcement learning* (RL) hay học tăng cường.

Nếu đặt cơ chế này vào bối cảnh chatbot của chúng ta, mọi thứ trở nên rất tự nhiên. “Ai đó” ở đây chính là mô hình ngôn ngữ lớn, hành động mà nó thực hiện là sinh ra một câu trả lời cho người dùng, và tín hiệu phản hồi là đánh giá từ con người cho biết câu trả lời đó có tốt hay không. Mục tiêu của quá trình học là cải thiện “chiến lược” trả lời của mô hình sao cho nó nhận được phản hồi tích cực ngày càng nhiều hơn.


Tại sao cách tiếp cận này lại phù hợp hơn cho bài toán alignment? Lý do rất đơn giản. Chúng ta không thể liệt kê tất cả các câu trả lời tốt và xấu vì không gian quá lớn. Chúng ta cũng không có một công thức sẵn để tính “chất lượng” câu trả lời. Điều duy nhất chúng ta có thể làm là để mô hình *thử* trả lời, rồi *nhận phản hồi* về kết quả, và *tự cải thiện* dần dần. Đây chính là vòng lặp cốt lõi mà RL cung cấp, và nó phù hợp một cách tự nhiên với bài toán alignment.



Hình 6: Vòng lặp alignment. Mô hình được huấn luyện, triển khai, thu thập phản hồi từ con người, sau đó tinh chỉnh bằng RL, và quy trình này được lặp lại liên tục.

Như minh họa tại Hình 6, toàn bộ quá trình alignment có thể được hình dung như một vòng lặp liên tục. Mô hình được huấn luyện, triển khai ra thực tế, thu thập phản hồi từ con người, và sau đó được tinh chỉnh bằng RL dựa trên những phản hồi đó. Đây là một quá trình cải thiện không ngừng, không phải là một bước duy nhất.

Nhưng vòng lặp này đặt ra một câu hỏi thực tế quan trọng. Phản hồi của con người đến từ đâu? Trong thực tế, cách hiệu quả nhất để thu thập phản hồi không phải là yêu cầu con người chấm điểm từng câu trả lời, mà là yêu cầu họ *so sánh* giữa hai câu trả lời và chọn câu nào tốt hơn. Cách tiếp cận này đơn giản hơn nhiều cho người đánh giá, vì việc nói “A tốt hơn B” dễ hơn rất nhiều so với việc cho điểm chính xác cho từng câu.



Hình 7: Quy trình thu thập dữ liệu ưu tiên từ con người. Người đánh giá so sánh hai câu trả lời cho cùng một câu hỏi và chọn câu trả lời tốt hơn.

Quy trình so sánh cặp đôi này được minh họa tại Hình 7. Với cùng một câu hỏi, mô hình sinh ra hai câu trả lời khác nhau, và người đánh giá chỉ cần cho biết câu nào tốt hơn. Dữ liệu thu thập từ quá trình này chính là “dữ liệu ưu tiên” mà chúng ta đã đề cập ở phần trước. Vậy câu hỏi tiếp theo là làm thế nào để sử dụng dữ liệu ưu tiên này một cách hiệu quả trong quá trình huấn luyện bằng RL?

VI. Reinforcement Learning from Human Feedback

Ở phần trước, chúng ta đã thấy rằng con người có thể cung cấp phản hồi bằng cách so sánh các cặp câu trả lời. Tuy nhiên, trong quá trình huấn luyện bằng RL, mô hình cần nhận được tín hiệu phần thưởng cho *mỗi* câu trả lời mà nó sinh ra. Rõ ràng là chúng ta không thể mời người đánh giá ngồi bên cạnh máy tính để chấm điểm cho hàng triệu câu trả lời trong suốt quá trình huấn luyện. Vậy giải pháp là gì? Câu trả lời nằm ở việc xây dựng một mô hình chuyên biệt có khả năng “thay mặt” con người để đánh giá. Mô hình này được gọi là *reward model* (hay mô hình phần thưởng).


VI.1. Mô hình phần thưởng

Ý tưởng của reward model rất đơn giản. Chúng ta sử dụng dữ liệu ưu tiên đã thu thập từ con người, tức các cặp câu trả lời đã được xếp hạng, để huấn luyện một mô hình riêng biệt. Mô hình này nhận vào một cặp gồm câu hỏi và câu trả lời, sau đó xuất ra một điểm số vô hướng

(*scalar score*) thể hiện mức độ “tốt” của câu trả lời đó theo tiêu chí của con người. Nói cách khác, reward model học cách mô phỏng “trực giác đánh giá” của con người và đóng vai trò như một người đánh giá tự động trong suốt quá trình huấn luyện RL.

i Reward Model là gì?

Reward model là một mô hình được huấn luyện trên dữ liệu ưu tiên của con người. Với mỗi cặp (câu hỏi, câu trả lời), nó xuất ra một điểm số thể hiện mức độ phù hợp với sở thích của con người. Reward model đóng vai trò như một “đại diện” cho đánh giá của con người, cho phép quá trình huấn luyện RL diễn ra tự động mà không cần sự hiện diện liên tục của người đánh giá.



Hình 8: Minh họa cách hoạt động của reward model. Mô hình nhận vào một cặp câu hỏi và câu trả lời, sau đó xuất ra một điểm số vô hướng thể hiện mức độ phù hợp với sở thích của con người.

Như minh họa tại Hình 8, reward model hoạt động như một hàm số đơn giản. Nó nhận đầu vào là một cặp câu hỏi và câu trả lời, rồi cho ra một con số duy nhất đại diện cho “chất lượng” của câu trả lời đó. Con số này chính là tín hiệu phần thưởng mà chúng ta sẽ sử dụng để huấn luyện mô hình ngôn ngữ bằng RL.

VI.2. Quy trình huấn luyện RLHF

Với reward model trong tay, chúng ta đã có đủ tất cả các thành phần cần thiết để xây dựng một quy trình hoàn chỉnh. Quy trình này được gọi là *reinforcement learning from human feedback* (RLHF) hay học tăng cường từ phản hồi con người, và nó bao gồm ba giai đoạn.


Giai đoạn 1 là SFT. Chúng ta bắt đầu với một mô hình đã được pre-train và tinh chỉnh nó bằng dữ liệu minh họa chất lượng cao. Giai đoạn này tạo ra một phiên bản mô hình “cơ sở” biết cách tuân theo chỉ dẫn và có phong cách trả lời phù hợp.

Giai đoạn 2 là huấn luyện reward model. Chúng ta thu thập dữ liệu ưu tiên từ con người bằng cách cho họ so sánh các cặp câu trả lời, sau đó huấn luyện một reward model để dự đoán sở thích của con người.

Giai đoạn 3 là tinh chỉnh bằng RL. Sử dụng mô hình SFT từ giai đoạn 1 làm điểm xuất phát, chúng ta cho mô hình sinh ra các câu trả lời, dùng reward model từ giai đoạn 2 để chấm điểm, và cập nhật mô hình để tối đa hóa điểm thưởng.



Giữ cho mô hình không “đi lạc” Trong giai đoạn 3, có một chi tiết quan trọng. Nếu chúng ta chỉ đơn giản tối đa hóa điểm thưởng mà không có ràng buộc gì, mô hình có thể “chơi gian” bằng cách sinh ra những câu trả lời kỳ lạ để đánh lừa reward model, thay vì thực sự trả lời tốt hơn. Để tránh điều này, quá trình huấn luyện sử dụng một cơ chế như “sợi dây an toàn” để giữ cho mô hình mới không đi quá xa so với mô hình SFT ban đầu. Chi tiết kỹ thuật của cơ chế này sẽ được trình bày trong buổi học chính.



Hình 9: Minh họa quy trình tạo ra một LLM với ba giai đoạn huấn luyện: *pretraining*, *supervised finetuning* và *RLHF*.

Toàn bộ quy trình được tổng hợp tại Hình 9. Và đến đây, có lẽ bạn đọc sẽ bất ngờ khi biết rằng tất cả những gì chúng ta vừa cùng nhau xây dựng từng bước một, từ ý tưởng thu thập phản hồi của con người, huấn luyện một mô hình phần thưởng, cho đến việc dùng reinforcement learning để tinh chỉnh mô hình ngôn ngữ lớn, *chính xác* là quy trình được sử dụng để tạo ra **InstructGPT** [2], nền tảng trực tiếp của **GPT-3.5** và sau này là **ChatGPT**.

Đây không phải là sự trùng hợp. Bài toán alignment là có thật, những giới hạn của SFT là có thật, và RLHF là một trong những câu trả lời quan trọng nhất đã được tìm ra sau nhiều năm nỗ lực. InstructGPT [2] đã chứng minh rằng quy trình này không chỉ hoạt động trên lý thuyết, mà còn mang lại những cải thiện đáng kể và rõ rệt trong thực tế, biến một mô hình ngôn ngữ mạnh mẽ nhưng “thô” thành một trợ lý ảo thực sự hữu ích, an toàn và đáng tin cậy.

VII. Kết luận

Trong bài viết này, chúng ta đã cùng nhau đi qua một hành trình từ ý tưởng đơn giản là triển khai một LLM dưới dạng chatbot, đến nhận ra rằng năng lực ngôn ngữ đơn thuần chưa đủ để tạo nên một trợ lý đáng tin cậy. Chúng ta đã thấy rằng SFT, dù là bước nền tảng quan trọng, có những giới hạn căn bản trong việc dạy mô hình về sở thích và giá trị của con người. Và cuối cùng, chúng ta đã khám phá ra rằng RLHF cung cấp một giải pháp có nguyên tắc cho bài toán alignment, thông qua vòng lặp thử nghiệm, phản hồi và cải thiện liên tục.

Trên thực tế, ngày nay các thuật toán RL đã và đang đóng một vai trò ngày càng quan trọng trong việc cải thiện chất lượng của LLM, trở thành một trong những kỹ thuật *post-training* (hậu huấn luyện) quan trọng bên cạnh SFT. Nhiều phương pháp alignment đã được phát triển dựa trên nền tảng RL, từ Proximal Policy Optimization (PPO) cho đến Direct Preference Optimization (DPO) và các biến thể khác, mỗi phương pháp đều mang lại những cải tiến riêng cho quá trình xây dựng các LLM an toàn và hữu ích hơn.

Hy vọng bài viết này đã giúp bạn đọc có được trực giác ban đầu về khái niệm LLM alignment cũng như lý do tại sao RL lại là công cụ phù hợp cho bài toán này. Đây là nền tảng “tại sao” để từ đó bạn đọc có thể tiếp tục tìm hiểu sâu hơn về các thuật toán cụ thể như Proximal Policy Optimization (PPO), Direct Preference Optimization (DPO) và nhiều phương pháp alignment khác.

VIII. Tài liệu tham khảo

- [1] Y. Bai et al., “Training a helpful and harmless assistant with reinforcement learning from human feedback”, 2022. arXiv: [2204.05862](https://arxiv.org/abs/2204.05862) [cs.CL]. [Online]. Available: <https://arxiv.org/abs/2204.05862>.
- [2] L. Ouyang et al., “Training language models to follow instructions with human feedback”, in *Advances in Neural Information Processing Systems*, S. Koyejo et al., Eds., vol. 35, Curran Associates, Inc., 2022, pp. 27 730–27 744. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/b1efde53be364a73914f58805a001731-Paper-Conference.pdf.
- [3] P. F. Christiano et al., “Deep reinforcement learning from human preferences”, in *Advances in Neural Information Processing Systems*, I. Guyon et al., Eds., vol. 30, Curran Associates, Inc., 2017. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2017/file/d5e2c0adad503c91f91df240d0cd4e49-Paper.pdf.
- [4] D. M. Ziegler et al., “Fine-tuning language models from human preferences”, 2020. arXiv: [1909.08593](https://arxiv.org/abs/1909.08593) [cs.CL]. [Online]. Available: <https://arxiv.org/abs/1909.08593>.
- [5] N. Stiennon et al., “Learning to summarize with human feedback”, in *Advances in Neural Information Processing Systems*, H. Larochelle et al., Eds., vol. 33, Curran Associates, Inc., 2020, pp. 3008–3021. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2020/file/1f89885d556929e98d3ef9b86448f951-Paper.pdf.

Bảng thuật ngữ

Thuật ngữ	Tạm dịch	Mô tả
<i>Alignment</i>	Căn chỉnh	Quá trình điều chỉnh hành vi của mô hình sao cho phù hợp với ý định, giá trị và kỳ vọng của con người.
<i>Direct Preference Optimization (DPO)</i>	Tối ưu hóa ưu tiên trực tiếp	Phương pháp alignment không cần huấn luyện mô hình phần thưởng riêng biệt, tối ưu trực tiếp từ dữ liệu ưu tiên.
<i>Kullback-Leibler (KL) Divergence</i>	Độ phân kỳ KL	Thước đo khoảng cách giữa hai phân phối xác suất, được sử dụng để ngăn mô hình đi quá xa so với phiên bản gốc trong quá trình tinh chỉnh bằng RL.
<i>Language Model</i>	Mô hình ngôn ngữ	Thuật toán được thiết kế để ước lượng phân phối xác suất của một chuỗi từ ngữ, thực hiện nhiệm vụ dự đoán từ tiếp theo có khả năng xuất hiện cao nhất dựa trên ngữ cảnh đã cho.
<i>Proximal Policy Optimization (PPO)</i>	Tối ưu hóa chính sách gần	Thuật toán reinforcement learning phổ biến được sử dụng trong giai đoạn tinh chỉnh RLHF.
<i>Reinforcement Learning from Human Feedback (RLHF)</i>	Học tăng cường từ phản hồi con người	Phương pháp sử dụng phản hồi của con người để huấn luyện mô hình phần thưởng, sau đó dùng học tăng cường để tinh chỉnh mô hình ngôn ngữ.
<i>Reward Hacking</i>	Lạm dụng phần thưởng	Hiện tượng mô hình tìm cách tối ưu hóa chỉ số đo lường mà không thực sự cải thiện chất lượng câu trả lời.
<i>Reward Model</i>	Mô hình phần thưởng	Mô hình được huấn luyện để dự đoán mức độ ưu tiên của con người đối với các câu trả lời, xuất ra một điểm số vô hướng.
<i>Supervised Fine-tuning (SFT)</i>	Tinh chỉnh có giám sát	Phương pháp tinh chỉnh mô hình bằng dữ liệu minh họa do con người viết, mô hình học cách bắt chước các câu trả lời mẫu.

Thuật ngữ	Tạm dịch	Mô tả
<i>Sycophancy</i>	Xu nịnh	Hiện tượng mô hình có xu hướng đồng ý với người dùng ngay cả khi người dùng sai, do các mẫu đồng tình phổ biến trong dữ liệu huấn luyện.

Phụ lục

1. **Resources:** Các file dataset, code gợi ý (hint) và bài giải (solution) có thể được tải tại [đây](#). (**Lưu ý:** Sau khi hết deadline của phần bài này, ad mới copy các nội dung bài giải vào đường dẫn).

2. **Rubric:**

Mục	Kiến Thức	Đánh Giá
I.	- Khái niệm alignment và lý do cần thiết của nó đối với LLM. - Ba tiêu chí đánh giá alignment (helpful, harmless, honest). - Các rủi ro khi thiếu alignment (nội dung có hại, sycophancy, reward hacking). - Giới hạn của SFT trong bài toán alignment. - Lý do reinforcement learning phù hợp cho alignment. - Khái niệm reward model và cách thu thập dữ liệu preference. - Quy trình RLHF và các thuật toán liên quan.	- Hiểu được tại sao LLM sau khi pre-training và SFT vẫn chưa đủ an toàn để triển khai. - Phân biệt được dữ liệu minh họa (demonstration data) và dữ liệu ưu tiên (preference data). - Giải thích được tại sao RL phù hợp hơn supervised learning cho bài toán alignment. - Mô tả được quy trình RLHF gồm ba giai đoạn và vai trò của reward model trong quy trình đó. - Có thể ứng dụng RLHF cho một LLM.

3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại [đây](#). Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.

AIO_QAs-Verified

🔒 Nhóm Riêng tư · 1,6K thành viên



Hình 10: Hình ảnh group facebook AIO Q&A.



AI VIET NAM – AI COURSE 2025

Quiz: LLM Alignment

Dương Đình Thắng

Đỗ Minh Khá

Đinh Quang Vinh

Câu 1. Quan sát Hình 1 minh họa một cuộc hội thoại giữa người dùng và chatbot. Người dùng hỏi “Làm thế nào để tôi giảm cân nhanh?” và chatbot có bốn phương án trả lời (A, B, C, D).

Người dùng

Làm thế nào để tôi giảm cân nhanh?

A. Bạn nên nhịn ăn hoàn toàn trong 7 ngày, đây là cách giảm cân nhanh nhất mà tôi biết!

B. Giảm cân là một quá trình cần kết hợp chế độ ăn uống cân bằng và tập luyện đều đặn. Bạn nên tham khảo ý kiến chuyên gia dinh dưỡng để có kế hoạch phù hợp với sức khỏe của mình. Lưu ý rằng giảm cân quá nhanh có thể gây hại cho sức khỏe.

C. Tôi không thể trả lời câu hỏi này.

D. Tuyệt vời, bạn hỏi đúng người rồi! Bạn giỏi lắm! Cứ làm bất cứ điều gì bạn muốn, chắc chắn sẽ thành công thôi!

Hình 1: Bốn phương án trả lời của chatbot cho câu hỏi về giảm cân.


Dựa trên tiêu chí 3H (Helpful, Harmless, Honest) trong alignment, phương án trả lời nào thỏa mãn **đồng thời cả ba tiêu chí**?

- A. Phương án A
- B. Phương án B
- C. Phương án C
- D. Phương án D

Câu 2. Phát biểu nào sau đây **KHÔNG** phải là giới hạn của *supervised fine-tuning* (SFT) trong bài toán *alignment*?

- A. SFT chỉ dạy mô hình bắt chước các câu trả lời mẫu mà không dạy được cách đánh giá câu nào tốt hơn câu nào.
- B. SFT không thể bao phủ hết mọi tình huống mà người dùng có thể hỏi trong thực tế.
- C. SFT không thể dạy mô hình tuân theo chỉ dẫn (instruction following) của người dùng.
- D. SFT không có cơ chế phản hồi để mô hình tự cải thiện từ những lần trả lời chưa tốt.

Câu 3. Quan sát Hình 2 minh họa pipeline *Reinforcement Learning from Human Feedback* (RLHF) gồm ba giai đoạn. Giai đoạn thứ hai đã bị ẩn đi và thay bằng dấu “?”.



Hình 2: Pipeline RLHF ba giai đoạn với giai đoạn thứ hai bị ẩn.

Giai đoạn thứ hai (dấu “?”) trong Hình 2 tương ứng với bước nào?

- A. Thu thập thêm dữ liệu instruction-response để tiếp tục SFT.
- B. Huấn luyện *reward model* từ dữ liệu so sánh *preference* của con người.
- C. Áp dụng KL divergence để ràng buộc mô hình không đi quá xa so với bản gốc.
- D. Triển khai mô hình ra thực tế và thu thập phản hồi từ người dùng cuối.

Câu 4. Hiện tượng nào sau đây mô tả đúng nhất khái niệm **reward hacking** trong ngữ cảnh RLHF?

- A. Mô hình tìm ra cách khai thác lỗ hổng của *reward model* để đạt điểm thưởng cao mà không thực sự cải thiện chất lượng câu trả lời.
- B. Mô hình bị tấn công bởi hacker bên ngoài làm thay đổi trọng số của *reward model*.
- C. Mô hình từ chối trả lời mọi câu hỏi nhạy cảm để tránh bị phạt bởi *reward model*.
- D. Mô hình sao chép nguyên văn câu trả lời từ dữ liệu huấn luyện thay vì tự sinh câu trả lời mới.

Câu 5. Một *reward model* chấm điểm cho ba câu trả lời A, B, C đối với cùng một prompt, thu được kết quả như sau.

Câu trả lời	Reward score
A	0.85
B	0.42
C	0.71


Đồng thời, nhóm annotator đã so sánh từng cặp và đưa ra preference như sau.

Cặp so sánh	Preference
A vs B	A tốt hơn B
C vs A	C tốt hơn A
C vs B	C tốt hơn B

Reward model có nhất quán (*consistent*) với **tất cả** các preference của annotator không? Nếu không, cặp nào bị vi phạm?

- A. Có, reward model nhất quán với tất cả các preference.
- B. Không, cặp A vs B bị vi phạm vì $R(A) < R(B)$ nhưng annotator chọn A tốt hơn B.
- C. Không, cặp C vs A bị vi phạm vì $R(A) = 0.85 > R(C) = 0.71$ nhưng annotator chọn C tốt hơn A.
- D. Không, cặp C vs B bị vi phạm vì $R(B) > R(C)$ nhưng annotator chọn C tốt hơn B.

Câu 6. Quan sát Hình 3 minh họa chu trình *alignment* liên tục của một hệ thống LLM. Một trong bốn giai đoạn đã bị ẩn đi và thay bằng dấu “?”.



Hình 3: Chu trình alignment liên tục với một giai đoạn bị ẩn.

Giai đoạn bị ẩn (dấu “?”) trong Hình 3 tương ứng với bước nào?

- A. Đánh giá mô hình bằng benchmark tự động trên tập test cố định.
- B. Thu thập phản hồi từ người dùng thực tế (Collect Feedback).
- C. Huấn luyện lại mô hình từ đầu với dữ liệu mới.
- D. Tăng kích thước mô hình để cải thiện hiệu suất.

Câu 7. Tại sao *reinforcement learning* (RL) được cho là phù hợp hơn *supervised learning* cho bài toán *alignment*?

- A. RL có kiến trúc mạng phức tạp hơn nên học được biểu diễn tốt hơn supervised learning.
- B. RL cho phép mô hình thử nhiều cách trả lời, nhận tín hiệu phản hồi (reward signal) cho từng phương án, và cải thiện dần thông qua vòng lặp thử-sai (trial-and-error).

- C. RL không cần dữ liệu huấn luyện nên tiết kiệm chi phí thu thập dữ liệu hơn supervised learning.
- D. RL huấn luyện nhanh hơn supervised learning vì không cần tính gradient cho toàn bộ tham số.

Câu 8. Xét đoạn code Python sau sử dụng thư viện `transformers` để chấm điểm hai câu trả lời bằng một *reward model*.

```

1 from transformers import pipeline
2
3 reward_pipe = pipeline(
4     "text-classification",
5     model="OpenAssistant/reward-model-deberta-v3-large-v2"
6 )
7
8 prompt = "Explain what a black hole is."
9 response_a = ("A black hole is a region in space where "
10              "gravity is so strong that nothing, not "
11              "even light, can escape from it...")
12 response_b = ("Black holes are terrifying monsters "
13              "that will destroy everything!!")
14
15 score_a = reward_pipe(prompt + " " + response_a)[0]["score"]
16 score_b = reward_pipe(prompt + " " + response_b)[0]["score"]
17
18 print(f"Score A: {score_a:.4f}")
19 print(f"Score B: {score_b:.4f}")

```

Dựa trên các nguyên tắc alignment, câu trả lời nào **nên** nhận điểm cao hơn từ *reward model*, và vì sao?

- A. Response B nên nhận điểm cao hơn vì sử dụng ngôn ngữ mạnh mẽ, gây ấn tượng với người đọc.
- B. Response A nên nhận điểm cao hơn vì cung cấp thông tin khoa học chính xác và trung lập, thỏa mãn cả ba tiêu chí helpful, harmless, và honest.
- C. Hai response nên nhận điểm bằng nhau vì đều đề cập đến black hole.
- D. Response B nên nhận điểm cao hơn vì câu ngắn hơn, giúp người dùng tiếp nhận thông tin nhanh hơn.

Câu 9. Xét đoạn code Python sau tính thứ tự preference từ reward score và in ra ranking.

```

1 import numpy as np
2
3 scores = {"A": 0.85, "B": 0.42, "C": 0.71}
4 responses = list(scores.keys())
5
6 print("Preference ordering from reward model:")
7 for i in range(len(responses)):
8     for j in range(i+1, len(responses)):
9         r1, r2 = responses[i], responses[j]
10        if scores[r1] > scores[r2]:
11            print(f" {r1} > {r2}")

```

```
12         else:
13             print(f" {r2} > {r1}")
14
15 sorted_responses = sorted(
16     scores.keys(),
17     key=lambda x: scores[x],
18     reverse=True
19 )
20 print(f"\nRanking: {' > '.join(sorted_responses)}")
```

Nếu thay đổi giá trị `scores["B"]` từ 0.42 thành 0.90, ranking mới sẽ là gì?

- A. $A > C > B$
- B. $B > A > C$
- C. $A > B > C$
- D. $C > B > A$

Câu 10. Một nhóm annotator cần tạo bộ dữ liệu *preference* cho một prompt bằng cách so sánh từng cặp câu trả lời. Giả sử có $n = 5$ câu trả lời khác nhau cho prompt đó. Để tạo bộ dữ liệu *preference* **đầy đủ** (mỗi cặp được so sánh đúng một lần), nhóm annotator cần thực hiện bao nhiêu phép so sánh?

- A. 5
- B. 20
- C. 10
- D. 25